



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

TP 1: Wiretapping

23 de septiembre, 2023

Teoría de las Comunicaciones

Integrante	LU	Correo electrónico
Lakowsky, Manuel	511/21	mlakowsky@gmail.com
Vekselman, Natán	338/21	natanvek11@gmail.com
Arienti, Federico	316/21	fa.arianti@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (++54 +11) 4576-3300

<http://www.exactas.uba.ar>

1. INTRODUCCIÓN

Los llamados Medios de Acceso Compartido se utilizan al momento de establecer una comunicación entre dos o más computadoras. El término refiere, de manera general, a cualquier tipo de canal —tanto físico como lógico— que establece un conjunto de reglas y protocolos para la transmisión de datos entre dispositivos electrónicos.

Estos datos son, a su vez, divididos en paquetes más pequeños —también llamados tramas— para su transportación. Cada uno de ellos contiene información sobre los protocolos que encapsula, su origen y su destino. En el caso de paquetes de tipo *Unicast*, este destino es un dispositivo particular. Mientras que, en el caso de paquetes de tipo *Broadcast*, un emisor puede enviar su paquete a todos los nodos conectados a la misma red. Sin embargo, estos datos pueden ser capturados y estudiados por cualquier otro dispositivo conectado al medio —como en el caso de Ethernet— o que se encuentre en el área de alcance del emisor —como en el caso de Wi-fi—, independientemente de su tipo.

A lo largo de este trabajo analizaremos las características de tres redes domésticas particulares que modelaremos como fuentes de información nula con símbolos $\langle \textit{tipo de emisión, protocolo utilizado} \rangle$. En particular, capturaremos los diversos paquetes de datos que las circulan, analizaremos —de manera general— los protocolos que utilizan las distintas capas de cada red, y buscaremos tendencias y patrones entre las tramas.

2. MÉTODOS Y CONDICIONES DE LOS EXPERIMENTOS

Implementamos en *python*, con ayuda de las bibliotecas de *scapy*, *numpy* y el código provisto por la cátedra, una serie de funciones dedicadas al filtrado de paquetes —por tipo de protocolo y tipo de dispersión—, detección de símbolos —y su probabilidad de ocurrencia—, cálculo de la *información* que cada uno provee, y —en términos generales— el cálculo de la *entropía* de cada fuente. El Código 1 muestra la implementación de estas últimas dos funciones¹. En el caso del cálculo de la *entropía*, se aprovechó la sintaxis de comprensión de listas para definir los valores de la sumatoria.

```

1 def informacion(ps):
2     """
3     ps es la probabilidad de ocurrencia
4     del simbolo s en la fuente.
5     """
6     i = -np.log2(ps)
7     return i
8
9 def entropia(S):
10    """
11    S es una lista con las probabilidades
12    de cada simbolo en la fuente.
13    """
14    e = np.sum([(ps) * informacion(ps) for ps in S])
15    return e

```

CÓDIGO 1. Implementación del cálculo de *información* y de *entropía* en *python*.

¹El código concerniente a la detección de paquetes y armado de la fuente de información nula es omitido, ya que es aquel provisto por la cátedra

Para la experimentación, trabajaremos sobre el tráfico de tres redes diferentes:

- *red 1*: como observada por un host con acceso por conexión wi-fi, ubicado en un edificio céntrico de la ciudad.
- *red 2*: como observada por un host con acceso por conexión ethernet, ubicado en una zona suburbana de la ciudad.
- *red 3*: como observada por un host con conexión wi-fi ubicado en una casa en el norte de la provincia.

Podemos considerar la ubicación de cada uno de estos hosts como ubicaciones dentro de distintos anillos concéntricos, en términos de densidad poblacional, dentro del área metropolitana de Buenos Aires.

Para cada red, tomaremos muestras de 10,000 tramas en un horario y día —que suponemos— es de mayor tráfico (a partir de las 18 hs, un viernes), y controlaremos la interacción del host con la red. Esto es, las mediciones se realizarán bajo un contexto de *reposo* —minimizando la cantidad de paquetes enviados— y bajo uso *intensivo*, con el objetivo de medir la influencia del tráfico propio en la fuente resultante.

También, mediremos el tiempo de recolección de los datos, en el contexto de *reposo*, a fin de obtener una noción respecto al flujo de tramas por unidad de tiempo en cada una de las redes analizadas.

Respecto a la parte optativa, realizaremos un análisis de las direcciones IP dentro de los paquetes ARP. Ya que este es un protocolo de capa de enlace, y local a cada una de las redes, esto nos permitirá observar las IPs propias de cada red con mayor detalle. Para ello, capturaremos hasta 1000 tramas por red bajo un contexto de uso normal de los dispositivos, en diferentes horarios del día.

A partir de las tramas capturadas, generaremos una segunda fuente de información de memoria nula, tal que cada símbolo sea del tipo $\langle src\ ip, dst\ ip \rangle$. De este modo, de existir algún host *distinguido* —es decir, en términos de la cantidad de información que provee—, lo podremos identificar.

3. RESULTADOS

En primer lugar, observemos la distribución de los protocolos y tipos de paquetes resultantes de las capturas realizadas. La figura 1 muestra cuál fue la distribución —observada—, y su respectivas medidas de *información*, para los paquetes capturados mientras los hosts estaban en 'reposo'. Los protocolos encontrados fueron los siguientes.

- *IPv4* (2048): Es el protocolo de internet más ampliamente difundido, que utiliza direcciones de 32 bits representadas por 4 números separados por un punto. El mismo define la denominada *layer 3* de internet.
- *IPv6* (34525): Este protocolo es una expansión del *IPv4*, el cual posee direcciones de 128 bits. Básicamente, busca incrementar la cantidad de direcciones en la red y además tiene mejoras en cuestiones de administración y seguridad.
- *ARP* (2054): es un protocolo utilizado en redes de computadoras para mapear direcciones de nivel de red (como direcciones IP) a direcciones de nivel de enlace (como direcciones MAC) en una red local.

- *LLDP* (35020): es un protocolo de red de la *layer 2* utilizado en redes Ethernet y en otras tecnologías de capa de enlace. Su función principal es permitir a los dispositivos en una red descubrir y anunciar información sobre sí mismos y sus capacidades a otros dispositivos vecinos.
- ? (26734): es un protocolo que en la página de IEEE no aparece. Creemos que está relacionado a TCP.




FIGURA 1. *Probabilidad de ocurrencia e información, por símbolo, para las redes en reposo.*

Notar que, en todas las redes, más del 70 % de los paquetes utilizan el símbolo $\langle \textit{unicast}, 2048 \rangle$, que corresponde al protocolo *IPv4*. El 95,42 % para la *red 1*, 73,51 % para la *red 2* y 85,27 % para la *red 3*. Además, en menor medida aparecieron algunos paquetes de los protocolos *IPv6* (34525) y *ARP* (2054). En total, pudimos detectar 7 tipos diferentes de símbolos.

En particular, es de interés que la *red 2*, que utiliza Ethernet, tuvo la mayor incidencia de otros tipos de protocolos: el 26,13 % fueron paquetes *Unicast* sobre *IPv6*. Así también, hubo mayor variedad: detectamos tramas de los protocolos *LLDP* (35020) —propia de enlaces de nivel 2, como Ethernet—, y 26734.

Respecto a los tipos de emisión, notamos que fueron predominantemente de tipo *Unicast*. Sólo hubo 14 paquetes de tipo *Broadcast* en la *red 1*, 1 en la *red 2* y 366 en la *red 3* —de estos, 345 ocurrieron en conjunto al protocolo *ARP*—. Consideramos que la mayor incidencia en la *red 3* puede deberse a que se encuentra en una ubicación (relativamente) más remota.

Vemos, finalmente, que la *información* provista por cada símbolo, en cada fuente, es bastante variada. Sin embargo, notamos el comportamiento —evidente en base a la teoría— de la medida: los protocolos y tipos de emisión con menor ocurrencia aportan la mayor cantidad de información. En particular, los de tipo de emisión *Broadcast*.

Por otro lado, la figura 2 muestra cuál fue la distribución, y su respectiva medida de *información*, —observada— de los paquetes capturados mientras los hosts estaban realizando actividades 'intensas'.

Notamos que, en comparación, hay mucha menor variedad en los paquetes: el 99,94 %, 97,10 % y 99,98 % —respectivamente, para las redes 1, 2 y 3— fueron $\langle \textit{Unicast}, 2048 \rangle$.




FIGURA 2. Probabilidad de ocurrencia e información, por símbolo, para las redes en actividad *intensa*.

Así también, la *red 1* y la *red 3* sólo detectaron paquetes de tipo *Unicast* y, aparte del protocolo *IPv4*, sólo detectaron el *ARP*. Nuevamente, la *red 2* fue la más variada, siendo la única que detectó paquetes de tipo *Broadcast* (6 en total).

Consideramos que la mayor predominancia del tipo *Unicast* se debe a que, como los hosts están utilizando activamente la red, su entrada en la tabla de direccionamiento de los routers cercanos se mantiene. Luego, no se requieren enviar mensajes de *who-has* del protocolo *ARP*, que parece ser la principal fuente de paquetes del tipo *Broadcast* en las redes que analizamos. Algo interesante es que los mensajes *ARP* que sí ocurrieron fueron *Unicast* en las redes 1 y 3. Esto significa que no fueron resultado de un mensaje *who-has*, si no de algún otro tipo de interacción.

Finalmente, procedemos a evaluar los resultados generales de los experimentos. En primer lugar, medimos la entropía de cada una de las tres fuentes (una por cada red) con las tramas resultantes de las capturas en *reposo*. Las mismas se pueden apreciar en la figura 5.

red	entropía aproximada
<i>red 1</i>	0,293
<i>red 2</i>	0,862
<i>red 3</i>	0,793

FIGURA 3. Entropía de las fuentes de información nula derivadas de las mediciones realizadas sobre cada una de las redes bajo estudio.

Vemos que se puede esperar una mayor cantidad de información por símbolo en los modelos de las redes 2 y 3, en comparación al de la red 1. Creemos que esto se debe a que los símbolos en el modelo de la red 1 aparecen con menor dispersión.

En segundo lugar, medimos cuánto tiempo tardó cada red en capturar las 10000 tramas, para el contexto de *reposo*. La figura 4 muestra los resultados.

red	tiempo	tramas por segundo
<i>red 1</i>	4647	2,15
<i>red 2</i>	695	14,39
<i>red 3</i>	2222	4,5

FIGURA 4. Tiempo de recolección de 10000 tramas para cada una de las redes bajo estudio, en el contexto de *reposo*.

Parece interesante que la *red 2* de tipo Ethernet haya capturado tantas más tramas por segundo. Esto puede deberse al tipo de medio, pero puede haber otras razones en juego. Como, por ejemplo, la cantidad de otros hosts.

4. NODOS DISTINGUIDOS

En un primer lugar, observamos que en todas las fuentes los símbolos incluyendo las IPs propias del router y las máquinas utilizadas eran los más probables: en promedio, representaban un 70,6 % de los paquetes a lo largo de las redes, conformando un 90,2 % de los paquetes en las redes WiFi y un 34,1 % en la red Ethernet. Creemos que estos paquetes están realizando el intercambio de mensajes correspondientes a *who-has* del protocolo.

Estas diferencias pueden deberse a las particularidades de las redes. Mientras que en ambas redes WiFi habían pocos hosts además de los medidores, existían más de 10 hosts conectados al router de la red Ethernet, tanto por WiFi como por cable. De este modo, de requerir actualizar la tabla de direcciones, el router debía enviar los mensajes ARP a ambas redes. En consecuencia, disminuyó la probabilidad de aparición de los símbolos mencionados.

Por otro lado, al calcular las entropías de las redes obtenemos los siguientes valores:

red	entropía aproximada	entropía máxima teórica
<i>red 1</i>	1,515	4,169
<i>red 2</i>	3,651	5,169
<i>red 3</i>	1,818	3,807

FIGURA 5. Entropía de las fuentes de información nula basadas en las direcciones de los paquetes ARP.

Como puede observarse, la red de Ethernet presenta más del doble de entropía que ambas redes WiFi. Esto se debe a que la distribución de los símbolos en esta red es más uniforme en comparación a las otras dos. Con respecto a la entropía máxima, la segunda red es la que más se aproxima, llegando a más del 70 % de su cota teórica.

Observamos además un comportamiento inesperado con respecto a algunos pares de símbolos. En el protocolo ARP, se espera que la cantidad de paquetes en una dirección sea similar a los paquetes en la dirección contraria. Es decir, los símbolos $\langle ip1, ip2 \rangle$ e $\langle ip2, ip1 \rangle$ deberían tener una cantidad de apariciones cercanas. Esto se debe a que un host pregunta por una dirección IP, y el propietario responde. De todos modos, vemos que esto no fue necesariamente cierto para ninguna de las redes, donde se pudieron capturar hasta 10 veces más paquetes en una dirección comparado a su contraria. Creemos que esto puede deberse a pérdida de paquetes o al problema del nodo oculto.

Por último, notamos la aparición inesperada de la $ip = 0.0.0.0$ en algunos paquetes. Esta es una dirección ip utilizada en algunas configuraciones de red como *default gateway* de las tablas de enrutamiento.

5. CONCLUSIÓN

A lo largo de este informe analizamos el flujo de los paquetes en tres redes ubicadas en distintos lugares del área metropolitana de Buenos Aires. Pudimos observar que la mayoría de los paquetes son de tipo $\langle Unicast, IPv4 \rangle$ y que varía fuertemente el caudal de paquetes cuando la red está en uso por el host y cuando no.

A su vez, observamos que el porcentaje de paquetes de tipo *Broadcast* es prácticamente despreciable en comparación con los de tipo *Unicast*. Esto tiene sentido, ya que los paquetes del mismo tipo suelen ocurrir en el contexto de protocolos de control.

Sin embargo, consideramos que las muestras tomadas no fueron lo suficientemente representativas del comportamiento de la red. El momento del día, el tipo de conexión, la ubicación geográfica y la actividad del host son distintos factores que definen su comportamiento. La cantidad de muestras que tomamos no son suficientes para capturar estos aspectos correctamente: capturamos momentos aislados, sobre acceso específicos y en contextos particulares.

Finalmente, cabe destacar que la entropía máxima para una fuente de información nula se da en el caso en que los símbolos ocurren con equiprobabilidad, y corresponde con $\log_2(n)$ — donde n representa la cantidad de símbolos presentes—. Notamos que ninguna de las fuentes tuvo una entropía que se acerque a este límite teórico.