



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

TP 1: Wiretapping

23 de septiembre, 2023

Teoría de las Comunicaciones

Integrante	LU	Correo electrónico
Lakowsky, Manuel	511/21	mlakowsky@gmail.com
Vekselman, Natán	338/21	natanvek11@gmail.com
Arienti, Federico	316/21	fa.arianti@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (++54 +11) 4576-3300

<http://www.exactas.uba.ar>

ÍNDICE

1.	Introducción	2
2.	Métodos y condiciones de los experimentos	2
3.	Resultados	3
4.	Conclusión	5
5.	Nodos Distinguidos	6

1. INTRODUCCIÓN

Los llamados Medios de Acceso Compartido se utilizan al momento de establecer una comunicación entre dos o más computadoras. El término refiere, de manera general, a cualquier tipo de canal —tanto físico como lógico— que establece un conjunto de reglas y protocolos para la transmisión de datos entre dispositivos electrónicos.

Estos datos son, a su vez, divididos en paquetes más pequeños —también llamados tramas— para su transportación. Cada uno de ellos contiene información sobre los protocolos que encapsula, su origen y su destino. En el caso de paquetes de tipo *Unicast*, este destino es un dispositivo particular. Mientras que, en el caso de paquetes de tipo *Broadcast*, un emisor puede enviar su paquete a todos los nodos conectados a la misma red. Sin embargo, estos datos pueden ser capturados y estudiados por cualquier otro dispositivo conectado al medio —como en el caso de Ethernet— o que se encuentre en el área de alcance del emisor —como en el caso de Wi-Fi—, independientemente de su tipo.

A lo largo de este trabajo analizaremos las características de tres redes domésticas particulares que modelaremos como fuentes de información nula con símbolos $\langle \textit{tipo de emisión, protocolo utilizado} \rangle$. En particular, capturaremos los diversos paquetes de datos que las circulan, analizaremos —de manera general— los protocolos que utilizan las distintas capas de cada red, y buscaremos tendencias y patrones entre las tramas.

2. MÉTODOS Y CONDICIONES DE LOS EXPERIMENTOS

Implementamos en *python*, con ayuda de las bibliotecas de *scapy*, *numpy* y el código provisto por la cátedra, una serie de funciones dedicadas al filtrado de paquetes —por tipo de protocolo y tipo de dispersión—, detección de símbolos —y su probabilidad de ocurrencia—, cálculo de la *información* que cada uno provee, y —en términos generales— el cálculo de la *entropía* de cada fuente. El Código 1 muestra la implementación de estas últimas dos funciones¹. En el caso del cálculo de la *entropía*, se aprovechó la sintaxis de comprensión de listas para definir los valores de la sumatoria.

```

1 def informacion(ps):
2     """
3     ps es la probabilidad de ocurrencia
4     del simbolo s en la fuente.
5     """
6     i = -np.log2(ps)
7     return i
8
9 def entropia(S):
10    """
11    S es una lista con las probabilidades
12    de cada simbolo en la fuente.
13    """
14    e = np.sum([(ps) * informacion(ps) for ps in S])
15    return e

```

CÓDIGO 1. Implementación del cálculo de *información* y de *entropía* en *python*.

¹El código concerniente a la detección de paquetes y armado de la fuente de información nula es omitido, ya que es aquel provisto por la cátedra

Para la experimentación, trabajaremos sobre el tráfico de tres redes diferentes:

- *red 1*: como observada por un host con acceso por conexión wi-fi, ubicado en un edificio céntrico de la ciudad.
- *red 2*: como observada por un host con acceso por conexión ethernet, ubicado en una zona suburbana de la ciudad.
- *red 3*: como observada por un host con conexión wi-fi ubicado en una casa en el norte de la provincia.

Podemos considerar la ubicación de cada uno de estos hosts como ubicaciones dentro de distintos anillos concéntricos, en términos de densidad poblacional, dentro del área metropolitana de Buenos Aires.

Para cada red, tomaremos muestras de 10,000 tramas en un horario y día —que suponemos— es de mayor tráfico (a partir de las 18 hs, un viernes), y controlaremos la interacción del host con la red. Esto es, las mediciones se realizarán bajo un contexto de *reposo* —minimizando la cantidad de paquetes enviados— y bajo uso *intensivo*, con el objetivo de medir la influencia del tráfico propio en la fuente resultante.

También, mediremos el tiempo de recolección de los datos, en el contexto de *reposo*, a fin de obtener una noción respecto al flujo de tramas por unidad de tiempo en cada una de las redes analizadas.

Además, realizaremos un análisis de las direcciones IP dentro de los paquetes ARP. Ya que este es un protocolo de capa de enlace, y local para cada una de las redes, esto nos permitirá observar las IPs propias de cada red con mayor detalle. A partir de las tramas capturadas, generaremos una segunda fuente de información de memoria nula, tal que cada símbolo sea del tipo $\langle SRC, DST \rangle$. De este modo, de existir algún host *distinguido*, es decir que sobresale en la cantidad de información que provee, lo podremos identificar a través de los símbolos a los que pertenece.

3. RESULTADOS

En primer lugar, observemos la distribución de los protocolos y tipos de paquetes resultantes de las capturas realizadas. La figura 1 muestra cuál fue la distribución, y su respectiva medida de *información*, —observada— de los paquetes capturados mientras los hosts estaban en 'reposo'.

Notar que, en todas las redes, más del 70 % de los paquetes utilizan el símbolo $\langle unicast, 2048 \rangle$, que corresponde al protocolo IPv4: 95,42 % para la *red 1*, 73,51 % para la *red 2* y 85,27 % para la *red 3*. Además, en menor medida aparecieron algunos paquetes de los protocolos *IPv6* (34525) y *ARP* (2054). En total, pudimos detectar 6 tipos diferentes de protocolos.

En particular, es de interés que la *red 2*, que utiliza Ethernet, tuvo la mayor incidencia de otros tipos: el 26,13 % fueron paquetes *Unicast* sobre *IPv6*. Así también, hubo mayor variedad: detectamos tramas de los protocolos *LLDP* (35020) —propia de enlaces de nivel 2, como Ethernet—, y 26734, que no pudimos encontrar a qué protocolo corresponde.

Respecto a los tipos de emisión, notamos que fueron predominantemente de tipo *Unicast*. Sólo hubo 14 paquetes de tipo *Broadcast* en la *red 1*, 1 en la *red 2* y 366 en la *red 3* —de estos, 345 ocurrieron en conjunto al protocolo *ARP*—. Consideramos que la mayor incidencia en la *red 3* puede deberse a que se encuentra en una ubicación (relativamente) más remota.

Vemos, finalmente, que la *información* provista por cada símbolo, en cada fuente, es bastante variada. Sin embargo, notamos el comportamiento —evidente en base a la teoría— de




FIGURA 1. *Probabilidad de ocurrencia e información*, por símbolo, para las redes en reposo.

la medida: los protocolos y tipos de emisión con menor ocurrencia aportan la mayor cantidad de información. En particular, los de tipo de emisión *Broadcast*.

Por otro lado, la figura 2 muestra cuál fue la distribución, y su respectiva medida de *información*, —observada— de los paquetes capturados mientras los hosts estaban realizando actividades 'intensas'.




FIGURA 2. *Probabilidad de ocurrencia e información*, por símbolo, para las redes en actividad *intensa*.

Notamos que, en comparación, hay mucha menor variedad en los paquetes: el 99,94%, 97,10% y 99,98% —respectivamente, para las las redes 1, 2 y 3— fueron $\langle Unicast, 2048 \rangle$. Así también, la *red 1* y la *red 3* sólo detectaron paquetes de tipo *Unicast* y, aparte del protocolo *IPv4*, sólo detectaron el *ARP*. Nuevamente, la *red 2* fue la más variada, siendo la única que detectó paquetes de tipo *Broadcast* (6 en total).

Consideramos que la mayor predominancia del tipo *Unicast* se debe a que, como los hosts están utilizando activamente la red, su entrada en la tabla de direccionamiento de los routers

cercanos se mantiene. Luego, no se requieren enviar mensajes de *who-has* del protocolo *ARP*, que utilizan el tipo *Broadcast*.

Finalmente, procedemos a evaluar los resultados generales de los experimentos. En primer lugar, medimos la entropía de cada una de las tres fuentes (una por cada red) con las tramas resultantes de las capturas en *reposo*. Las mismas se pueden apreciar en la figura 3.

red	entropía aproximada
<i>red 1</i>	0,793
<i>red 2</i>	0,293
<i>red 3</i>	0,862

FIGURA 3. Entropía de las fuentes de información nula derivadas de las mediciones realizadas sobre cada una de las redes bajo estudio.

Vemos que se puede esperar una mayor cantidad de información por símbolo en los modelos de las redes 1 y 3, en comparación al de la red 2. Esto muestra que los símbolos en el modelo de la red 2 tienden a aparecer con menor dispersión.

Esto tiene sentido ya que, si bien fue la más variada, las anomalías fueron menos frecuentes que en las otras dos redes².

En segundo lugar, medimos cuánto tiempo tardó cada red en capturar las 10000 tramas, para el contexto de reposo *reposo*. La figura 4 muestra los resultados.

red	tiempo	tramas por segundo
<i>red 1</i>	4647	2,15
<i>red 2</i>	695	14,39
<i>red 3</i>	2222	4,5

FIGURA 4. Tiempo de recolección de 10000 tramas para cada una de las redes bajo estudio, en el contexto de *reposo*.

Consideramos que un análisis de este tipo requiere hacer más mediciones para lograr ser representativo, por lo que los resultados son limitados, en tanto lo que podemos derivar de ellos.

En la misma línea, como experimentación a futuro, consideramos que podríamos profundizar más el análisis si fuéramos a capturar las tramas en diferentes horarios y días de la semana.

4. CONCLUSIÓN

A lo largo de este informe analizamos el flujo de los paquetes en 3 redes ubicadas en distintos lugares de la ciudad. Pudimos observar que la mayoría de los paquetes son de tipo

²si consideramos que una frecuencia menor al 5 % es anómala, sigue que la *red 1* tuvo 4,57 % de paquetes anómalos, la *red 2* tuvo 0,35 % y la *red 3* tuvo 5,17 %.

UNICAST ipv4, también notamos que varía fuertemente el caudal de paquetes cuando la red esta en uso constante.

Notamos que las muestras tomadas no fueron en su totalidad representativas del comportamiento de la red.

Observamos que el porcentaje de paquetes de tipo BROADCAST es prácticamente despreciable en comparación con los de tipo UNICAST.

Capturando paquetes encontramos distintos tipos de protocolos, ellos son:

- IPV4 : 2048
- IPV6 : 34525
- ARP : 2054
- LLDP : 35020

IPV4 : Es el protocolo de internet más ampliamente difundido, este se caracteriza por ser una dirección de 32 bits representada por 4 números de 8 bits separados por '.', debido al crecimiento de la red de internet la cantidad de IPs diferentes se fue agotando por lo que se debieron implementar medidas para expandir la cantidad direccionable. Una estrategia fue generar un protocolo nuevo llamado IPV6. Otra fue permitir que varios dispositivos tengan una única dirección IP pública con el uso de NAT.

IPV6 : Este protocolo es una expansión del IPV4, el cual posee direcciones de 128 bits, típicamente representadas de forma hexadecimal por 8 números de 16 bits separados por ':'. Básicamente este existe para incrementar la cantidad de direcciones en la red pero además tiene mejoras en cuestiones de administración y seguridad.

ARP (Address Resolution Protocol) : es un protocolo utilizado en redes de computadoras para mapear direcciones de nivel de red (como direcciones IP) a direcciones de nivel de enlace (como direcciones MAC) en una red local.

LLDP (Link Layer Discovery Protocol) : es un protocolo de red de capa 2 utilizado en redes Ethernet y en otras tecnologías de capa de enlace. La función principal de LLDP es permitir que los dispositivos en una red descubran y anuncien información sobre sí mismos y sus capacidades a otros dispositivos vecinos.

La entropía máxima sabemos que corresponde con el $\log_2(n)$ donde n representa la cantidad de paquetes capturados.

También encontramos un protocolo número 26734, que no encontramos que protocolo representa.

5. NODOS DISTINGUIDOS

El objetivo de esta sección es analizar las direcciones IP provenientes de los paquetes ARP de las tres redes. En particular, buscamos distinguir símbolos y hosts de las fuentes creadas según la cantidad de información que proveen. Para ello, capturamos hasta 1000 tramas por red bajo un contexto de uso normal de los dispositivos, en diferentes horarios del día.

En un primer lugar, observamos que en todas las fuentes los símbolos incluyendo las IPs propias del router y las máquinas utilizadas eran los más probables: en promedio, representaban un 70,6 % de los paquetes a lo largo de las redes. Creemos que esto puede deberse a las particularidades de las redes; en ambas redes WiFi donde representaron un 90,2 % de los paquetes habían pocos hosts además de los medidores, mientras que en la red Ethernet ??? sera que cambia por el uso que le dimos a las pcs?